高级语言程序设计研究性教学

（2025-2026第一学期）

一、 研究性学习目标

通过实际应用问题的分析与实现，使学生了解和掌握先进的计算机领域内的算法，体会程序、算法和实际问题之间的关系。

二、 知识点覆盖

多模块程序设计，数组，指针，文件，查找，向量运算，相似性

三、 实验内容

实验 1：相似性计算

在现实应用中，经常需要衡量不同个体之间的相异或相似程度，欧氏距离、余弦系数和雅可比系数就是最常用的一些度量个体间的距离或相似性的指标。

请根据如下定义和函数原型分别实现各个相似性度量函数：

（1） 给定向量 A = (a_1, a_2,..., a_n), B = (b_1, b_2,..., b_n)，写出如下函数计算两个向量代表的个体间的欧氏距离：

double EuclideanDistance(double *pVectorA, double *pVectorB, int nVectorLen);

（2） 给定向量 A = (a_1, a_2,..., a_n), B = (b_1, b_2,..., b_n)，求两个向量间的余弦系数的公式为：

$$CosCoef(A,B)=\frac{\sum_{i=1}^{n} a_i b_i}{\sqrt{\sum_{i=1}^{n} a_i^2 \sum_{i=1}^{n} b_i^2}}$$

根据以上公式完成如下函数，计算两个向量所代表的个体间的余弦系数相似性：

double CosCoef(double *pVectorA, double *pVectorB, int nVectorLen);

注：pVectorA 和 pVectorB 分别为指向长度为 nVectorLen 的 double 型数组的首个单元的指针变量。

实验 2：聚类算法的实现（可以借助大模型实现，自行调试，并对代码质量进行评估**）**

（1） 自学并实现聚类算法 K-Means（可参考补充材料），将实验数据 Iris.data 中的数据划分成三个类，并统计划分的精度。

（2） 思考题扩展：数据聚类在现实世界中的作用是什么，有哪些常见的聚类方法。K-means 算法存在哪些问题，存在哪些解决方法。

补充材料：k 均值聚类(K-means)

本部分首先介绍聚类的基础——距离与相异度，然后介绍一种常见的聚类算法——k 均值和 k 中心点聚类，最后会举一个实例：应用聚类方法试图解决一个在体育界大家颇具争议的问题——中国男足近几年在亚洲到底处于几流水平。

1、相异度计算

在正式讨论聚类前，我们要先弄清楚一个问题：如何定量计算两个可比较元素间的相异度。用通俗的话说，相异度就是两个东西差别有多大，例如人类与章鱼的相异度明显大于人类与黑猩猩的相异度，这是能我们直观感受到的。但是，计算机没有这种直观感受能力，我们必须对相异度在数学上进行定量定义。

设$X=\{x_1,x_2,...,x_n\},Y=\{y_1,y_2,...,y_n\}$，其中 X，Y 是两个元素项，各自具有 n 个可度量特征属性，那么 X 和 Y 的相异度定义为：$d(X,Y)=f(X,Y)\rightarrow R$，其中 R 为实数域。也就是说相异度是两个元素对实数域的一个映射，所映射的实数定量表示两个元素的相异度。

下面介绍不同类型变量相异度计算方法。

1.1、标量

标量也就是无方向意义的数字，也叫标度变量。现在先考虑元素的所有特征属性都是标量的情况。例如，计算 X={2,1,102}和 Y={1,3,2}的相异度。一种很自然的想法是用两者的欧几里得距离来作为相异度，欧几里得距离的定义如下：

$$d(X,Y)=\sqrt{(x_1-y_1)^2+(x_2-y_2)^2+...+(x_n-y_n)^2}$$

其意义就是两个元素在欧氏空间中的集合距离，因为其直观易懂且可解释性强，被广泛用于标识两个标量元素的相异度。将上面两个示例数据代入公式，可得两者的欧氏距离为：

$$d(X,Y)=\sqrt{(2-1)^2+(1-3)^2+(102-2)^2}=100.025$$

除欧氏距离外，常用作度量标量相异度的还有曼哈顿距离和闵可夫斯基距离，两者定义如下：

曼哈顿距离：$d(X,Y)=|x_1-y_1|+|x_2-y_2|+...+|x_n-y_n|$

闵可夫斯基距离：$d(X,Y)=\sqrt[p]{|x_1-y_1|^p+|x_2-y_2|^p+...+|x_n-y_n|^p}$

欧氏距离和曼哈顿距离可以看做是闵可夫斯基距离在 p=2 和 p=1 下的特例。另外这三种距离都可以加权，这个很容易理解，不再赘述。

下面要说一下标量的规格化问题。上面这样计算相异度的方式有一点问题，就是取值范围大的属性对距离的影响高于取值范围小的属性。例如上述例子中第三个属性的取值跨度远大于前两个，这样不利于真实反映真实的相异度，为了解决这个问题，一般要对属性值进行规格化。所谓规格化就是将各个属性值按比例映射到相同的取值区间，这样是为了平衡各个属性对距离的影响。通常将各个属性均映射到[0,1]区间，映射公式为：

$$a_i'=\frac{a_i-min(a_i)}{max(a_i)-min(a_i)}$$

其中 max(ai)和 min(ai)表示所有元素项中第 i 个属性的最大值和最小值。例如，将示例中的元素规格化到[0,1]区间后，就变成了 X’ ={1,0,1}，Y’ ={0,1,0}，重新计算欧氏距离约为 1.732。

1.2、二元变量

所谓二元变量是只能取 0 和 1 两种值变量，有点类似布尔值，通常用来标识是或不是这种二值属性。对于二元变量，上一节提到的距离不能很好标识其相异度，我们需要一种更适合的标识。一种常用的方法是用元素相同序位同值属性的比例来标识其相异度。

设有 X={1,0,0,0,1,0,1,1}，Y={0,0,0,1,1,1,1,1}，可以看到，两个元素第 2、3、5、7 和 8 个属性取值相同，而第 1、4 和 6 个取值不同，那么相异度可以标识为 3/8=0.375。一般的，对于二元变量，相异度可用“取值不同的同位属性数/单个元素的属性位数”标识。

上面所说的相异度应该叫做对称二元相异度。现实中还有一种情况，就是我们只关心两者都取 1 的情况，而认为两者都取 0 的属性并不意味着两者更相似。例如在根据病情对病人聚类时，如果两个人都患有肺癌，我们认为两个人增强了相似度，但如果两个人都没患肺癌，并不觉得这加强了两人的相似性，在这种情况下，改用“取值不同的同位属性数/(单个元素的属性位数-同取 0 的位数)”来标识相异度，这叫做非对称二元相异度。如果用 1 减去非对称二元相异度，则得到非对称二元相似度，也叫 Jaccard 系数，是一个非常重要的概念。

1.3、分类变量

分类变量是二元变量的推广，类似于程序中的枚举变量，但各个值没有数字或序数意义，如颜色、民族等等，对于分类变量，用“取值不同的同位属性数/单个元素的全部属性数”来标识其相异度。

1.4、序数变量

序数变量是具有序数意义的分类变量，通常可以按照一定顺序意义排列，如冠军、亚军和季军。对于序数变量，一般为每个值分配一个数，叫做这个值的秩，然后以秩代替原值当做标量属性计算相异度。

1.5、向量

对于向量，由于它不仅有大小而且有方向，所以闵可夫斯基距离不是度量其相异度的好办法，一种流行的做法是用两个向量的余弦度量，其度量公式为：

$$s(X,Y)=\frac{X^tY}{||X||||Y||}$$

其中||X||表示 X 的欧几里得范数。要注意，余弦度量度量的不是两者的相异度，而是相似度！

2、聚类问题

在讨论完了相异度计算的问题，就可以正式定义聚类问题了。

所谓聚类问题，就是给定一个元素集合 D，其中每个元素具有 n 个可观察属性，使用某种算法将 D 划分成 k 个子集，要求每个子集内部的元素之间相异度尽可能低，而不同子集的元素相异度尽可能高。其中每个子集叫做一个簇。

与分类不同，分类是示例式学习，要求分类前明确各个类别，并断言每个元素映射到一个类别，而聚类是观察式学习，在聚类前可以不知道类别甚至不给定类别数量，是无监督学习的一种。目前聚类广泛应用于统计学、生物学、数据库技术和市场营销等领域，相应的算法也非常的多。本文仅介绍一种最简单的聚类算法——k 均值（k-means）算法。

3、K-means 算法及其示例

k 均值算法的计算过程非常直观：

（1） 从 D 中随机取 k 个元素，作为 k 个簇的各自的中心。

（2） 分别计算剩下的元素到 k 个簇中心的相异度，将这些元素分别划归到相异度最低的簇。

（3） 根据聚类结果，重新计算 k 个簇各自的中心，计算方法是取簇中所有元素各自维度的算术平均数。

（4） 将 D 中全部元素按照新的中心重新聚类。

（5） 重复第 4 步，直到聚类结果不再变化。

（6） 将结果输出。

由于算法比较直观，没有什么可以过多讲解的。下面，我们来看看 k-means 算法一个有趣的应用示例：中国男足近几年到底在亚洲处于几流水平？

今年中国男足可算是杯具到家了，几乎到了过街老鼠人人喊打的地步。对于目前中国男足在亚洲的地位，各方也是各执一词，有人说中国男足亚洲二流，有人说三流，还有人说根本不入流，更有人说其实不比日韩差多少，是亚洲一流。既然争论不能解决问题，我们就让数据告诉我们结果吧。

下图是我采集的亚洲 15 只球队在 2005 年-2010 年间大型杯赛的战绩（由于澳大利亚是后来加入亚足联的，所以这里没有收录）。

	A	B	C	D
1		2006年世界杯	2010年世界杯	2007年亚洲杯
2	中国	50	50	9
3	日本	28	9	4
4	韩国	17	15	3
5	伊朗	25	40	5
6	沙特	28	40	2
7	伊拉克	50	50	1
8	卡塔尔	50	40	9
9	阿联酋	50	40	9
10	乌兹别克斯坦	40	40	5
11	泰国	50	50	9
12	越南	50	50	5
13	阿曼	50	50	9
14	巴林	40	40	9
15	朝鲜	40	32	17
16	印尼	50	50	9

EricZhang's Tech Blog (http://leoo2sk.cnblogs.com)

其中包括两次世界杯和一次亚洲杯。我提前对数据做了如下预处理：对于世界杯，进入决赛圈则取其最终排名，没有进入决赛圈的，打入预选赛十强赛赋予 40，预选赛小组未出线的赋予 50。对于亚洲杯，前四名取其排名，八强赋予 5，十六强赋予 9，预选赛没出现的赋予 17。这样做是为了使得所有数据变为标量，便于后续聚类。

下面先对数据进行[0,1]规格化，下面是规格化后的数据：

	A	B	C	D
1		2006年世界杯	2010年世界杯	2007年亚洲杯
2	中国	1	1	0.5
3	日本	0.3	0	0.19
4	韩国	0	0.15	0.13
5	伊朗	0.24	0.76	0.25
6	沙特	0.3	0.76	0.06
7	伊拉克	1	1	0
8	卡塔尔	1	0.76	0.5
9	阿联酋	1	0.76	0.5
10	乌兹别克斯坦	0.7	0.76	0.25
11	泰国	1	1	0.5
12	越南	1	1	0.25
13	阿曼	1	1	0.5
14	巴林	0.7	0.76	0.5
15	朝鲜	0.7	0.68	1
16	印尼	1	1	0.5

EricZhang's Tech Blog (http://leoo2sk.cnblogs.com)

接着用 k-means 算法进行聚类。设 k=3，即将这 15 支球队分成三个集团。

现抽取日本、巴林和泰国的值作为三个簇的种子，即初始化三个簇的中心为 A：{0.3, 0, 0.19}，B：{0.7, 0.76, 0.5}和 C：{1, 1, 0.5}。下面，计算所有球队分别对三个中心点的相异度，这里以欧氏距离度量。下面是我用程序求取的结果：

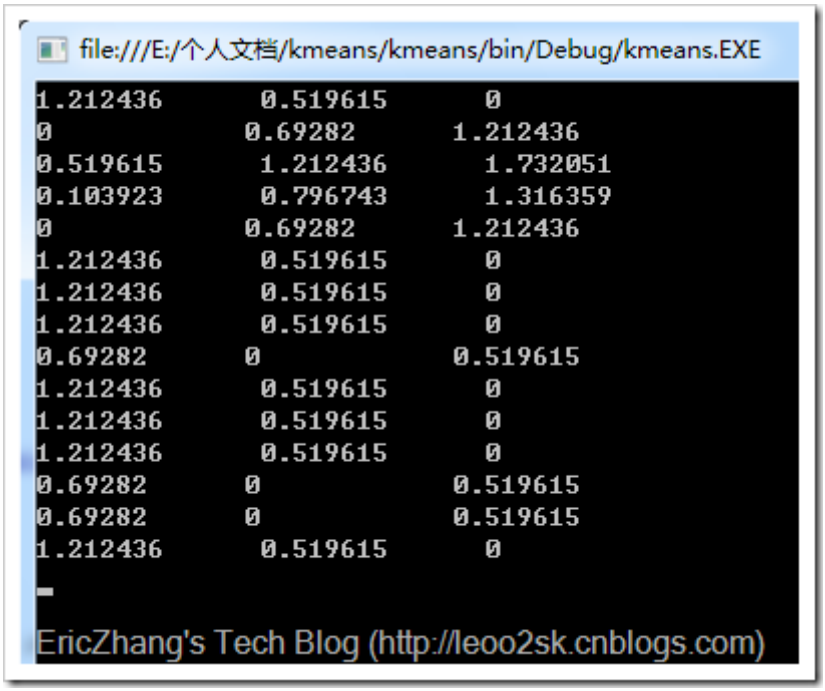

从做到右依次表示各支球队到当前中心点的欧氏距离，将每支球队分到最近的簇，可对各支球队做如下聚类：

中国 C，日本 A，韩国 A，伊朗 A，沙特 A，伊拉克 C，卡塔尔 C，阿联酋 C，乌兹别克斯坦 B，泰国 C，越南 C，阿曼 C，巴林 B，朝鲜 B，印尼 C。

第一次聚类结果：

A：日本，韩国，伊朗，沙特；

B：乌兹别克斯坦，巴林，朝鲜；

C：中国，伊拉克，卡塔尔，阿联酋，泰国，越南，阿曼，印尼。

下面根据第一次聚类结果，调整各个簇的中心点。

A 簇的新中心点为：{(0.3+0+0.24+0.3)/4=0.21, (0+0.15+0.76+0.76)/4=0.4175, (0.19+0.13+0.25+0.06)/4=0.1575} = {0.21, 0.4175, 0.1575}

用同样的方法计算得到 B 和 C 簇的新中心点分别为{0.7, 0.7333, 0.4167}，{1, 0.94, 0.40625}。

用调整后的中心点再次进行聚类，得到：

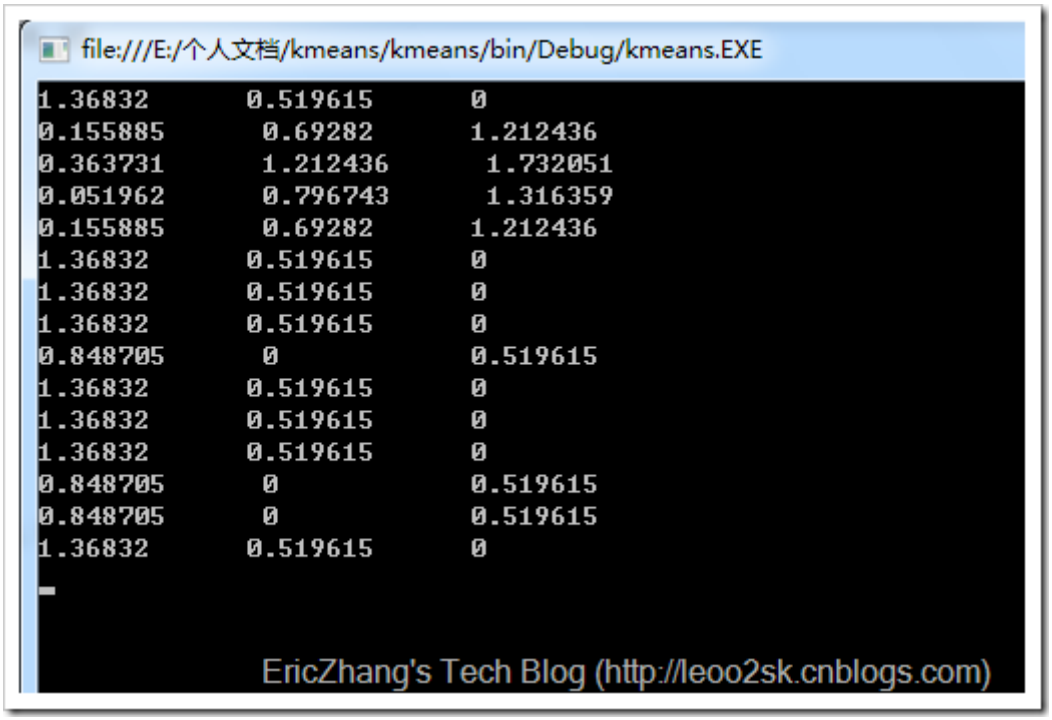

第二次迭代后的结果为：

中国 C，日本 A，韩国 A，伊朗 A，沙特 A，伊拉克 C，卡塔尔 C，阿联酋 C，乌兹别克斯坦 B，泰国 C，越南 C，阿曼 C，巴林 B，朝鲜 B，印尼 C。

结果无变化，说明结果已收敛，于是给出最终聚类结果：

亚洲一流：日本，韩国，伊朗，沙特

亚洲二流：乌兹别克斯坦，巴林，朝鲜

亚洲三流：中国，伊拉克，卡塔尔，阿联酋，泰国，越南，阿曼，印尼

看来数据告诉我们，说国足近几年处在亚洲三流水平真的是没有冤枉他们，至少从国际杯赛战绩是这样的。

其实上面的分析数据不仅告诉了我们聚类信息，还提供了一些其它有趣的信息，例如从中可以定量分析出各个球队之间的差距，例如，在亚洲一流队伍中，日本与沙特水平最接近，而伊朗则相距他们较远，这也和近几年伊朗没落的实际相符。另外，乌兹别克斯坦和巴林虽然没有打进近两届世界杯，不过凭借预算赛和亚洲杯上的出色表现占据 B 组一席之地，而朝鲜由于打入了 2010 世界杯决赛圈而有幸进入 B 组，可是同样奇迹般夺得 2007 年亚洲杯的伊拉克却被分在三流，看来亚洲杯冠军的分量还不如打进世界杯决赛圈重啊。其它有趣的信息，有兴趣的朋友可以进一步挖掘。